Python 培训第四期

Pandas初步

By 李亚军

CONTENT

- Intro and Installation
- Object Creation
- Viewing Data
- Selection
- Missing Data
- File IO
- Visualization

Intro and Installation

- Pandas 是一个 Python 数据分析方面的开源库，含有使数据分析工作变得更快更简单的高级数据结构和操作工具，基于 Numpy 构建。
- 和其他第三方包安装方式一样，可以采用 conda 或者 pip 方式安装。

```
$ conda install pandas
```

```
$ pip install pandas
```

Object Creation

- Pandas 中最主要的两个数据结构就是 *Series* 和 *DataFrame*，前者是类似于一维数组的结构，而后者是表格类似结构。

- Series 和 DataFrame 的创建可以有多种方法，其中 Series 可以用列表和字典来创建，而 DataFrame 最多的而是用等长列表或者 Numpy 数组组成的字典。

Object Creation - Series

```
In [4]: ser = Series([4, 7, -5, 3])
In [5]: ser
Out[5]:
0 4
1 7
2 -5
3 3
dtype: int64
In [9]: ser2 = Series([4, 7, -5, 3], index=['a', 'b', 'c', 'd'])
In [10]: ser2
Out[10]:
a 4
b 7
c -5
d 3
dtype: int64
In [13]: ser3 = Series({'a': 4, 'b': 7, 'c': -5, 'd':3})
```

Object Creation - DataFrame

使用字典构建 DataFrame

```
In [22]: df = DataFrame({'col1': np.arange(5),
                         'col2': np.arange(5, 10),
                         'col3': np.arange(10, 15),
                         'col4': np.arange(15, 20)})

In [23]: df

Out[23]:
   col1 col2 col3 col4
0     0    5   10   15
1     1    6   11   16
2     2    7   12   17
3     3    8   13   18
4     4    9   14   19
```

Object Creation - DataFrame

为 DataFrame 指定行名和列名

```
In [25]: df1 = DataFrame(np.arange(20).reshape((5, 4)),
                         index=['row1', 'row2', 'row3', 'row4', 'row5'],
                         columns=['col1', 'col2', 'col3', 'col4'])

In [26]: df1

Out[26]:
      col1 col2 col3 col4
row1     0    1    2    3
row2     4    5    6    7
row3     8    9   10   11
row4    12   13   14   15
row5    16   17   18   19
```

Viewing Data

- 我们可以使用一些基本函数来查看一个 DataFrame 的数据。

函数	说明
df.head()	查看 df 的前 n 行，默认前 5 行
df.tail()	查看 df 的后 n 行，默认后 5 行
df.index	查看 df 的索引
df.columns	查看 df 的列名
df.values	查看 df 的值

Selection

- Series 的值选取方法类似于 Numpy 数组的选取，只不过 Series 可以根据 index 来索引，而 index 不一定是整数。

```
In [29]: ser = Series(np.arange(4), index=list('abcd'))
In [30]: ser
Out[30]:
a 0
b 1
c 2
d 3
dtype: int32
In [31]: ser['c'] # ser[2]
Out[31]: 2
In [32]: ser['b':'d']
Out[32]:
b 1
c 2
d 3
dtype: int32
```

Selection

- DataFrame 的选择可以通过 .loc，.iloc 和 .ix 函数，也可以使用类似字典选取的方式。

函数	说明
df[val]	选取某一列或者多列
df.loc[]	依据行名和列名来选取值
df.iloc[]	依据位置来选取值
df.ix[]	既可依据行名列名，也可依据位置，但行名列名优先

Selection

```
In [41]: df['col1']
Out[41]:
row1 0
row2 4
row3 8
row4 12
row5 16
Name: col1, dtype: int32

In [47]: df.loc['row2', 'col3']
Out[47]: 6

In [49]: df.iloc[1, 2]
Out[49]: 6

In [50]: df.ix[1, 2] # df.ix['row2', 'col3']
Out[50]: 6
```

Missing Data

- Pandas 中有一些方便的处理缺失值的方法。

方法	说明
df.dropna()	删除存在缺失值的行或列
df.fillna()	用指定值或差值方法填充缺失数据
df.isnull()	判断是否是缺失值
df.notnull()	判断是否不是缺失值

File IO

- Pandas 提供了很多高级函数来读取和写入数据文件。

方法	说明
read_csv()	读取 CSV 文件
read_excel()	读取 Excel 文件
read_table()	读取带分隔符的文件，默认分隔符为制表符
read_hdf()	读取 HDF5 数据文件
read_pickle()	读取 pickle 数据文件
read_clipboard()	读取剪贴板的数据

Visualization

- Pandas 有许多能够利用 DataFrame 对象的数据组织特点来创建图标的高级绘图方法。

方法	说明
plot()	默认绘制折线图
bar()	条形图
scatter()	散点图
hist()	直方图

Visualization

```
In [2]: ts = pd.Series(np.random.randn(1000),
                       index=pd.date_range('1/1/2000',
                                           periods=1000))

In [3]: ts = ts.cumsum()

In [4]: ts.plot()
Out[4]: <matplotlib.axes._subplots.AxesSubplot at
0x17cdc8255f8>

In [5]: plt.show()
```

Visualization

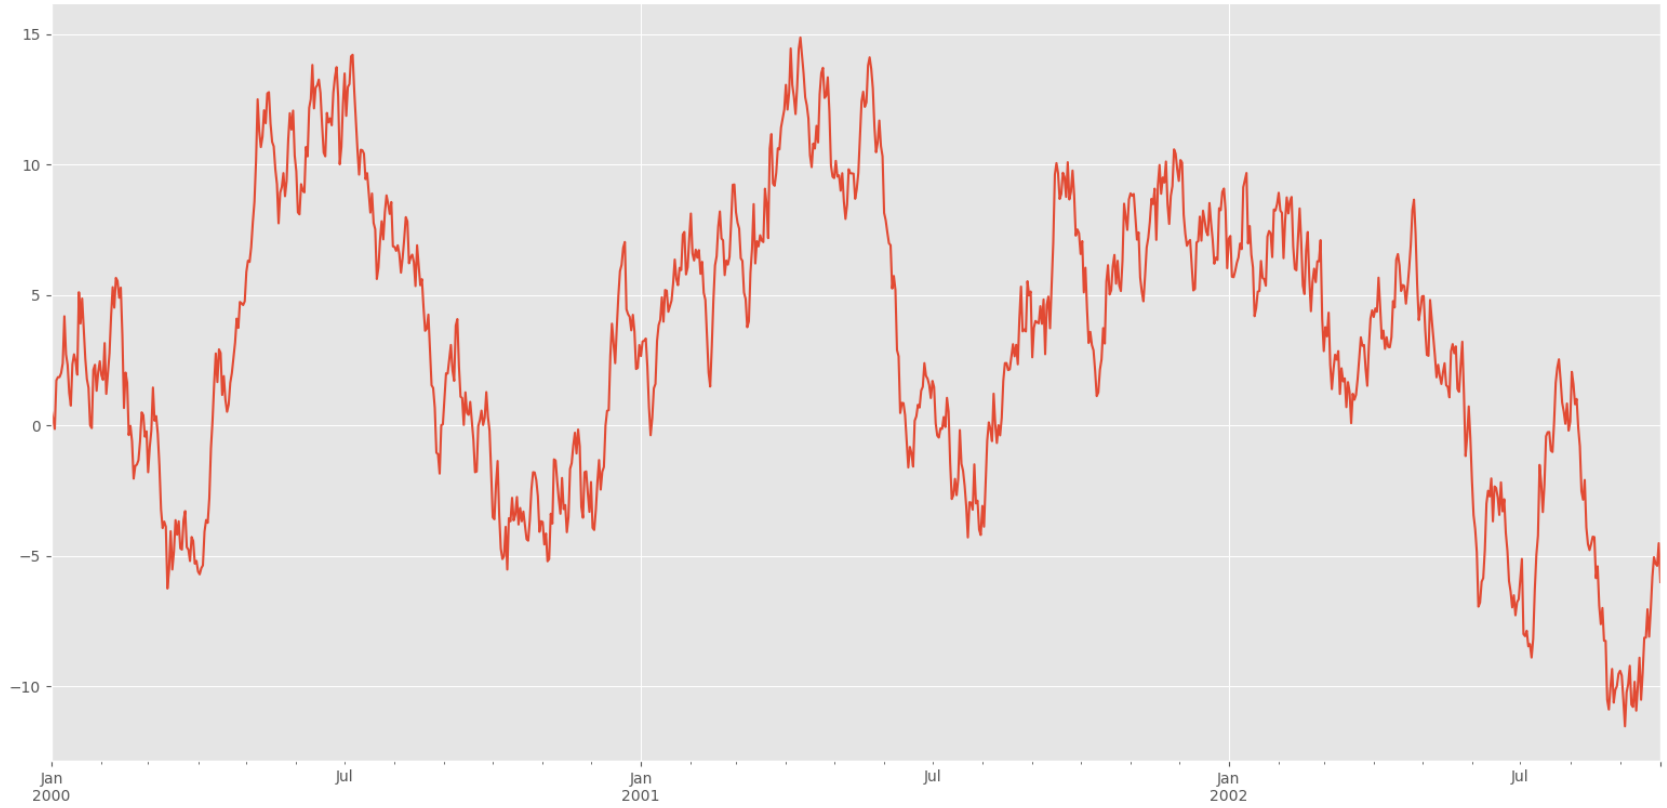

Visualization

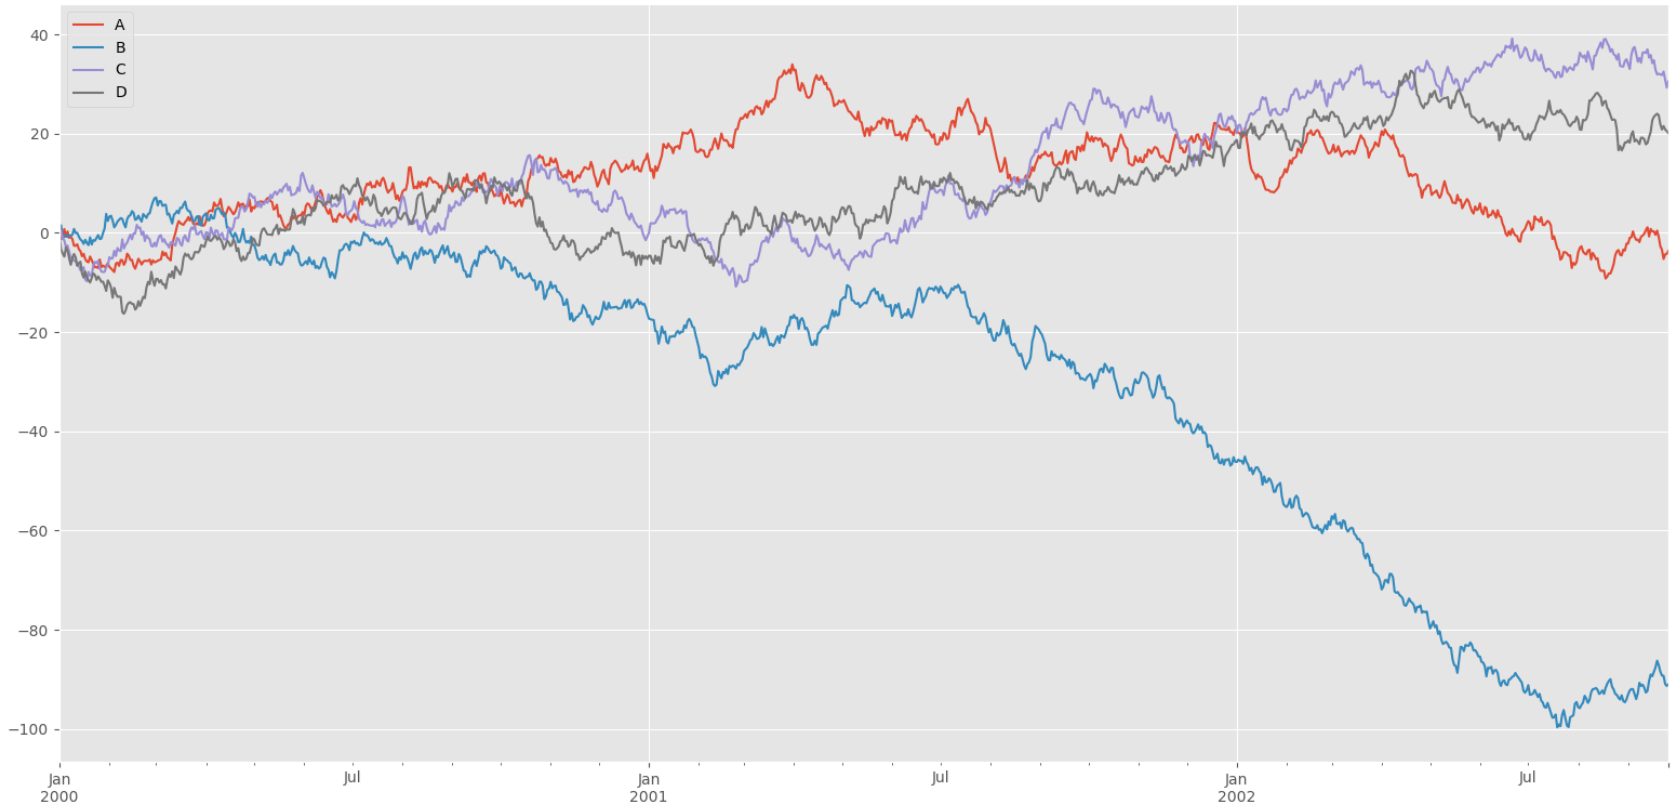

Visualization

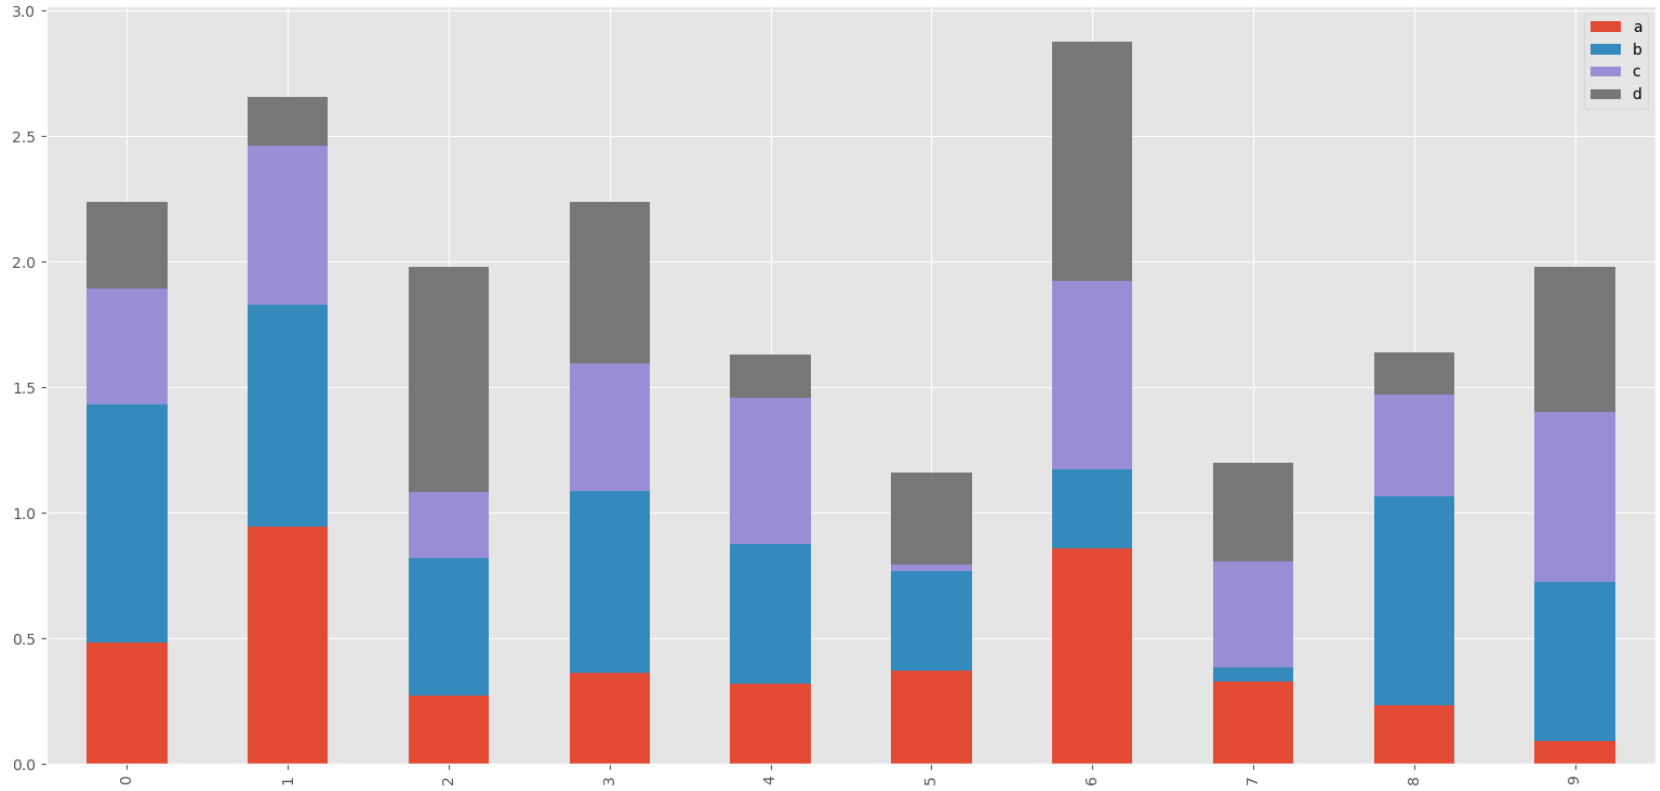

Visualization

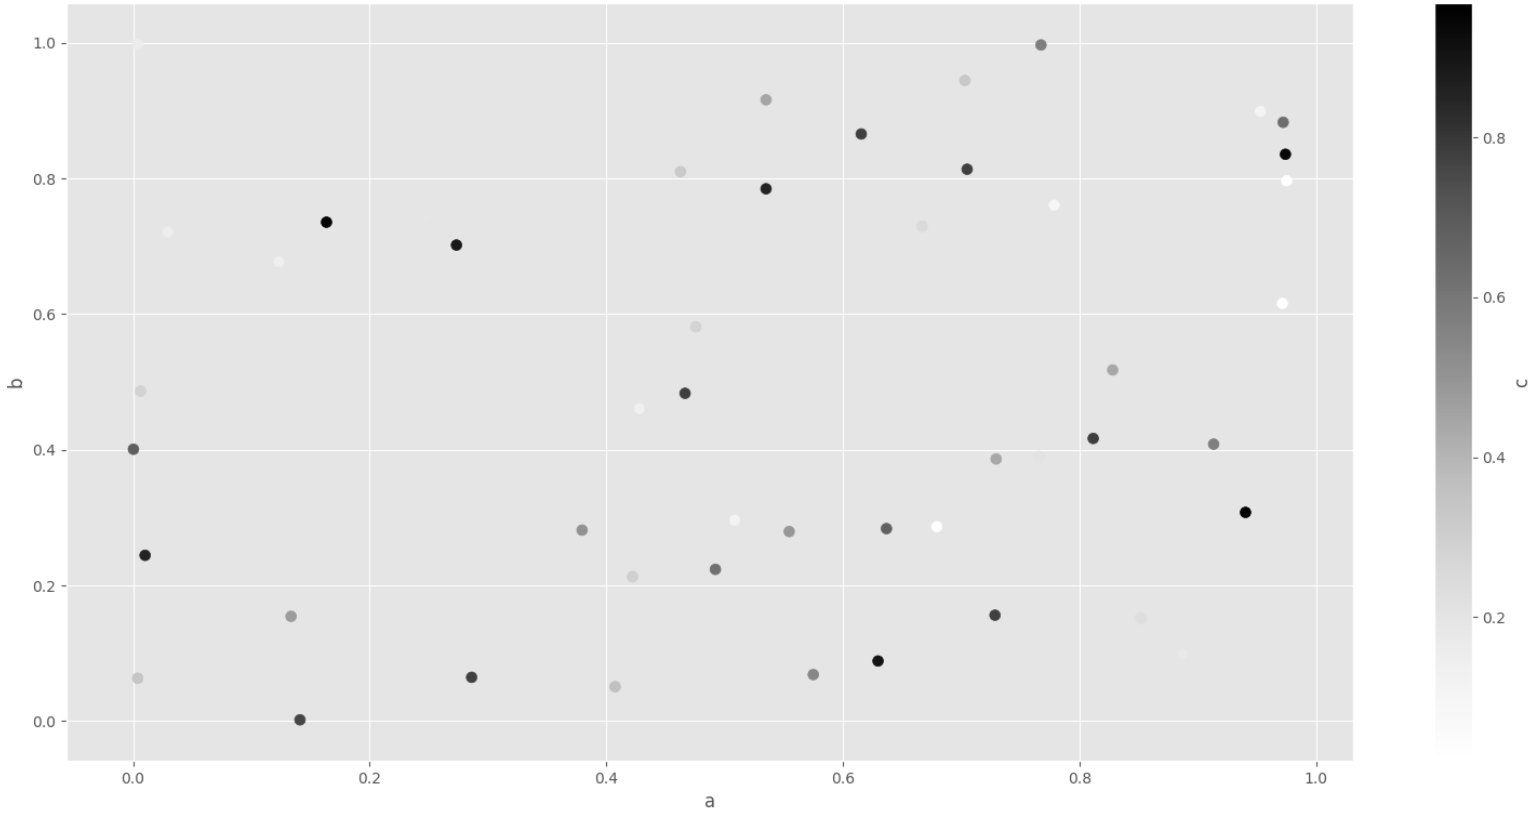

THANK YOU
FOR LISTENING